

УНИВЕРЗИТЕТ У БЕОГРАДУ
ЕЛЕКТРОТЕХНИЧКИ ФАКУЛТЕТ



ПОЗИЦИОНИРАЊЕ У *INDOOR* ОКРУЖЕЊУ ПРИМЕНОМ ТЕХНИКА МАШИНСКОГ УЧЕЊА

Дипломски рад

Ментор:
Др Александар Нешковић
Редовни професор

Кандидат:
Лука Хаџић 2020/0385

Београд, октобар 2025.

Садржај

САДРЖАЈ	I
1. УВОД	1
2. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА – ОСНОВНИ ПОЈМОВИ И ПРИМЕНА	2
2.1. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА VS. МАШИНСКО УЧЕЊЕ	2
2.2. ЗАДАЦИ МОДЕЛА ВЕШТАЧКЕ ИНТЕЛИГЕНЦИЈЕ	2
2.3. АЛГОРИТМИ ТРЕНИРАЊА МОДЕЛА ВЕШТАЧКЕ ИНТЕЛИГЕНЦИЈЕ	2
2.4. ОПТИМИЗАЦИЈА ХИПЕРПАРАМЕТАРА	3
3. INDOOR ПОЗИЦИОНИРАЊЕ КОРИШЋЕЊЕМ AI I WLAN	4
3.1. ОСОБИНЕ ПРОБЛЕМА И РЕШЕЊА НА КОНКРЕТНОМ ПРИМЕРУ	4
3.2. ФОРМИРАЊЕ БАЗЕ ПОДАКА	4
3.3. ОСНОВНИ СИСТЕМ	5
3.4. СЕКТОРИЗАЦИЈА ПРОСТОРА	5
3.5. СИСТЕМ СА СЕКТОРИЗАЦИЈОМ ПРОСТОРА	6
3.5.1. SVC класификатор	7
3.5.2. SVR модели у секторима	7
3.6. СИСТЕМ СА ВИШЕ КЛАСИФИКАТОРА	7
4. ДОБИЈЕНИ РЕЗУЛТАТИ И ЊИХОВА АНАЛИЗА	9
4.1. АНАЛИЗА ОСНОВНОГ SVR МОДЕЛА	9
4.1.1. Анализа параметара	9
4.2. АНАЛИЗА СИСТЕМА СА ЈЕДНИМ SVC КЛАСИФИКАТОРОМ И СЕКТОРИЗАЦИЈОМ ПРОСТОРА	9
4.2.1. Подела на два сектора – један SVC	11
4.2.2. Подела на четири сектора – један SVC	11
4.2.3. Подела на шест сектора – један SVC	11
4.2.4. Подела на осам сектора – један SVC	11
4.2.5. Подела на десет сектора – један SVC	11
4.2.6. Подела на дванаест сектора – један SVC	12
4.3. АНАЛИЗА СИСТЕМА СА ВИШЕ КЛАСИФИКАТОРА И СЕКТОРИЗАЦИЈОМ ПРОСТОРА	13
4.3.1. Подела на два сектора – више класификатора	14
4.3.2. Подела на четири сектора – више класификатора	14
4.3.3. Подела на шест сектора – више класификатора	14
4.3.4. Подела на осам сектора – више класификатора	14
4.3.5. Подела на десет сектора – више класификатора	14
4.3.6. Подела на дванаест сектора – више класификатора	14
5. ЗАКЉУЧАК	16
6. ЛИТЕРАТУРА	17
СПИСАК СКРАЋЕНИЦА	18
СПИСАК СЛИКА	19
СПИСАК ТАБЕЛА	20

1. Увод

Како је на отвореном простору позиционирање корисника са великом тачношћу реализовано применом GPS (*Global Positioning System*) система, а који се у затвореном простору не може увек применити због великих слабљења сигнала, маскирања компонената сигнала и фединга услед вишеструке пропагације, јавља се потреба за коришћењем другачијег начина позиционирања у затвореном окружењу [1]. Једна од идеја је позиционирање коришћењем WLAN (*Wireless Local Area Network*) мрежа. Њихова велика распрострањеност као и приступачност чини овакав вид позиционирања доста повољним и једноставним за имплементацију.

Поставља се питање зашто користити машинско учење. За многе проблеме у телекомуникацијама, коришћење машинског учења се показало тачнијим и учинковитијим од коришћења компликованих математичких формула и статистичких модела. Побољшање капацитета рачунарских компонената, пре свега моћи процесора, омогућило је примену ових техника за рачунски захтевне, сложене телекомуникационе примене. Време за које истрениран систем базиран на машинском учењу даје резултате може бити знатно краће, а сам поступак процесорски мање захтеван од израчунавања сложених формула сваки појединачни пут.

Циљ овог рада је минимизација грешке позиционирања корисника у *indoor* окружењу помоћу WLAN мрежа и техника машинског учења. Коришћењем одређених алата вештачке интелигенције и машинског учења, а на основу података о нивоима снаге сигнала (RSSI – *Received Signal Strength Indicator*) са различитих приступних тачака, биће анализирана поузданост оваквог система. Допринос рада се огледа у побољшању карактеристика поменутог система увођењем секторизације простора и већинског одлучивања.

Структура рада организована је на следећи начин: у другом поглављу биће укратко објашњене коришћене технике машинског учења, описане архитектуре модела и оптимизација хиперпараметра. У трећем поглављу, биће описан коришћен скуп података и биће представљене архитектуре машинског учења. У четвртном поглављу биће приказани експериментални резултати као и њихова анализа. Пето поглавље садржи закључак рада и коментар о могућим начинима даљег унапређења система позиционирања.

2. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА – ОСНОВНИ ПОЈМОВИ И ПРИМЕНА

Објашњење појмова неопходних за разумевање основних концепата вештачке интелигенције биће представљено у оквиру овог поглавља. Направљена је разлика између машинског учења и вештачке интелигенције, објашњен појам модела вештачке интелигенције и његови основни задаци. Објашњени су принципи основних алгоритама за тренирање ових модела заједно са својим хиперпараметрима као и њиховом оптимизацијом.

2.1. Вештачка интелигенција vs. машинско учење

Вештачка интелигенција (AI–*Artificial Intelligence*) је област информатике која се бави развојем система који треба да изврше задатке за које је потребна људска интелигенција. То се постиже коришћењем различитих модела обучених за извршавање таквих задатака. Велики број проблема вештачка интелигенција решава са веома добром тачношћу и значајно штеди време и енергију који би били уложени за њихово решавање [2].

Машинско учење (ML–*Machine Learning*) је већински подскуп вештачке интелигенције који подразумева обучавање тј. тренирање поменутих модела разним алгоритмима на одређеним подацима. Дати алгоритми се у већој мери заснивају на сложеним математичким законитостима и теоријама, а представљају поступак за проналажење генералних образаца и зависности између података одређеног проблема [2]. Скуп података на ком се модели обучавају се зове тренинг скуп података, а сами подаци тренинг подаци.

Модел вештачке интелигенције представља алгоритамски оквир који симулира употребу људске интелигенције за решавање одређеног проблема. На основу тренинг података модел учи обрасце конкретних проблема и прилагођава своје параметре како би се постигла што боља генерализација проблема. Поменути модели могу да врше процесе класификације и регресије.

2.2. Задаци модела вештачке интелигенције

Класификација представља процес одређивања класе жељеног податка из унапред дефинисаног скупа. То се постиже на основу улазних података који представљају битне особине податка чију класу треба одредити. Улазна обележја (*features*) дефинише човек или сам модел кроз његово обучавање. Битно је напоменути да је скуп могућих класа дискретан скуп. [2].

Регресија представља процес предикције вредности из континуалног скупа података на основу улазних обележја. Регресиони модел кроз процес тренирања треба да одреди математичку зависност између излазних и улазних података. Регресија се може дефинисати и као класификација са континуалним, бесконачно великим скупом могућих класа [2].

2.3. Алгоритми тренирања модела вештачке интелигенције

Неки од алгоритама који се могу користити за тренирање модела вештачке интелигенције, а који су коришћени приликом решавања проблема *indoor* позиционирања

корисника коришћењем WLAN мрежа су: SVM (*Support Vector Machine*), kNN (*k-Nearest Neighbor*) и MLP (*Multilayer Perceptron*).

SVM представља један од најутицајнијих алгоритама машинског учења [2]. Циљ овог модела је да пронађе границу односно хиперраван која ће најтачније раздвојити класе у n -димензионом простору података, где n представља број улазних обележја. Поменута граница се формира у односу на податке који се налазе најближе граници а који се називају *support vectors*, тако да растојање између елемената различитих класа буде што веће. Хиперпараметри који утичу на рад SVM алгорита су: C – ширина софт маргине у којој се грешке класификације/регресије не кажњавају, *kernel* – функција трансформације улазних података, *epsilon* – представља казну за направљену грешку класификације/регресије и *gamma* – утиче на закривљеност границе која раздваја различите класе.

kNN је један од једноставнијих алгоритама машинског учења који за велики број проблема пружа одличне перформансе и тачност. Може се користити и за класификацију и за регресију. Основни принцип рада је позиционирање податка у n -димензионом простору података на основу k најближих суседа из скупа података за тренинг. Хиперпараметри овог алгорита машинског учења су: $n_neighbors$ – број суседа (k) који се узимају у обзир приликом доношења одлуке, *metric* – начин дефинисања растојања између узорака и *weights* – начин на који суседи утичу на позиционирање податка у n -димензионом простору података, односно да ли ће сви суседи имати подједнак утицај.

MLP је врста вештачке неуронске мреже која се састоји од улазног, излазног и једног или више скривених слојева. Слојеви се састоје из неурона који су задужени за пријем и одговарајућу обраду сигнала на основу своје активационе функције. Она представља законитост којом се од улазних вредности неурона добија излазна. Активационом функцијом – множењем улазних вредности тежинским коефицијентима и додавањем скаларних вредности, уводи се нелинеарност и омогућава решавање нелинеарних проблема [2]. Овакав модел може се користити и за класификацију и за регресију. Помоћу *backpropagation* алгорита се може извршити оптимизација тежинских коефицијената неурона и тиме доћи до најбоље тачности оваквог модела. Хиперпараметри овог алгорита машинског учења су: *hidden_layer_sizes* – број неурона у сваком скривеном слоју, *activation* – активациона функција која омогућава решавање нелинеарних проблема, *solver* – алгоритам који ће се користити за оптимизацију, *batch_size* – број узорака који ће се користити у једном кораку ажурирања тежинских коефицијената неурона, *learning_rate* – промена корака учења приликом тренирања модела и *alpha* – контролише L2 регуларизацију - омогућава да модел посматра улазне податке са већом варијансом - подаци чија је коваријанса са излазном вредношћу мала у поређењу са додатом варијансом се означавају као мање значајне карактеристике и вредности њихових тежинских коефицијената се смањују [2].

2.4. Оптимизација хиперпараметара


Оптимизација хиперпараметара модела машинског учења може се извршити помоћу методе *GridSearchCV* из *Python* библиотеке *scikit-learn* [3]. Овај метод подразумева испитивање различитих комбинација хиперпараметара (сваки са сваким) и одређивање најбоље комбинације. Може се применити и *k-fold* крос-валидација како би се побољшала способност генерализације модела и смањила вероватноћа да се модел претренира (*overfitting*) – модел ће научити генералне особине проблема, а не локалне зависности тренинг скупа података.

3. INDOOR ПОЗИЦИОНИРАЊЕ КОРИШЋЕЊЕМ AI I WLAN

Основна идеја *indoor* позиционирања корисника коришћењем WLAN мрежа на конкретном примеру зграде Електротехничког факултета Универзитета у Београду биће објашњена у наставку. Описан је начин прикупљања података, нивои снаге сигнала и позиције на којима су вршена мерења. Биће приказана архитектура основног система и неколико реализација које обезбеђују побољшање прецизности и стабилности самог позиционирања.

3.1. Особине проблема и решења на конкретном примеру

Зграда ЕТФ-а поседује осам инсталираних WLAN приступних тачака (*Access Points*) који су распоређених да пруже оптимално покривање радио сигналом за бежични приступ интернету (Слика 3.1.1). Основна идеја била је следећа: на основу нивоа измерене снаге сигнала на пријемнику предиктовати локацију корисника.



Слика 3.1.1. Положај *access point*-а и вршених мерења у згради ЕТФ-а

3.2. Формирање базе података

За потребе имплементације претходно објашњене идеје неопходно је формирати базу података. Она представља табелу у којој првих осам колона одређује ниво снаге сигнала са одговарајућих *access point*-а изражен у dBm. Девета и десета колона означавају x и y координату у којој је вршено мерење гледано од координатног почетка (Слика 3.1.1). Координате су представљене у пикселима, где 1 пиксел одговара 0.1m у простору. Свака врста табеле представља информације о једном мерењу. У једној локацији вршена су мерења за четири оријентације корисничког пријемника, 0° , 90° , 180° и 270° . Ако је ниво снаге пријемног сигнала са *Access Point*-а испод прага пријема, за вредност нивоа снаге сигнала се уписује карактер "*". Мерења су извршена у 403 референтне тачке, означене на Слици 3.1.1, што са четири оријентације у свакој тачки укупно даје 1612 података.

У току обраде добијених података, карактер "*" замењен је са вредношћу -100dBm што представља праг пријема пријемника који је коришћен приликом мерења. За потребе

секторизације простора, рачунања перформанси како предикционих модела тако и различитих система, у процесу су креиране и помоћне табеле које су суштински копије основне базе података.

Подаци који се користе за тренирање односно тестирање модела су подељени у односу 90:10 приближно равномерно у простору.

3.3. Основни систем


Основни систем базиран је на једном SVR моделу. На основу вектора обележја у виду новоа снаге сигнала са *access point*-а, модел учи о позицији корисника. Како је скуп резултат предикције низ од две вредности – x и y координата положаја, а не једна вредност, треба нагласити да поменути SVR није класичан регресиони модел, већ MultiOutputRegressor - комбинација у овом случају два SVR модела, један модел предвиђа једну координату [3]. Како би се добила што боља тачност, хиперпараметри модела су оптимизовани *GridSearchCV* методом. На Слици 3.3.1. приказана је архитектура система.



Слика 3.3.1. Шема основног система

3.4. Секторизација простора


Секторизација простора извршена је искључиво геометријски, на основу димензија зграде ЕТФ-а и жељеног броја сектора, правим хоризонталним и вертикалним линијама. Податак припада сектору ако његова x и y координата припадају том сектору. Ознака да је податак у неком од сектора врши се уписом броја одговарајућег сектора у помоћну табелу. На Слици 3.4.1. може се видети подела података по секторима.



Слика 3.4.1. Приказ поделе података на укупно дванаест сектора

3.5. Систем са секторизацијом простора

Унапређење у односу на претходни систем је коришћење више сектора простора уместо само једног основног сектора. Секторизација простора подразумева и коришћење SVC класификатора који ће одредити ком сектору податак припада. У сваком сектору, налази се по један SVR модел као из основног система, који ће предиктовати позицију само у оквиру датог сектора. На Слици 3.5.1. у наставку може се видети шема оваквог система, где је класификациони модел изабрао да податак припада сектору два.



Слика 3.5.1. Шема система са једним SVC и секторизацијом простора

3.5.1. SVC класификатор


SVC класификатор система има задатак да на основу улазног вектора обележја одреди ком сектору податак припада. За повећање тачности овог модела, коришћена је *GridSearchCV* метода оптимизације хиперпараметара. Наведени класификатор има осам улаза – вектор вредности нивоа снаге сигнала, и један излаз који представља редни број сектора ком податак припада.

3.5.2. SVR модели у секторима

На основу SVC класификатора одређено је ком сектору податак припада. Након тога, SVR модел из изабраног сектора одређује координате односно позицију корисника. За сваки сектор се користи посебан модел, чији су хиперпараметри оптимизовани *GridSearchCV* методом. Тренирање ових SVR модела извршено је на деловима тренинг скупа који припадају одговарајућим секторима. Тестирање модела је извршено аналогно тренирању - најпре је тест скуп подељен по секторима, а затим је одговарајућим SVR моделима које одређује класификација предиктована позиција података и на основу тога су евалуиране перформансе модела. Подела тест скупа података по секторима нема никаквог утицаја на одабир SVR модела, већ искључиво за одређивање статистичких параметара и тачности система.

3.6. Систем са више класификатора

Систем са више класификатора представља унапређење претходног, јер се за потребе одређивања сектора ком податак припада користи неколико различитих класификационих модела. Основна идеја је повећање тачности класификације, а самим тим и целокупног система. Како различити типови класификационих модела дају различите предикције, уведен је и принцип већинског одлучивања који на основу већине класификатора одређује број сектора. Од ова четири типа класификације - SVC, kNN, MLP и већинско одлучивање, за даљу класификацију користиће се онај који пружа најбољу тачност, чиме се не допушта да модели лошије тачности утичу на смањење највеће доступне тачности класификације. За одређени број сектора и избор података за тренинг скуп, поново се прерачунава тачност модела и бира најбоља опција. Већинско одлучивање потенцијално може дати бољи резултат, односно, повећати тачност класификатора у конкретном случају. На Слици 3.6.1. у наставку налази се шема оваквог система, где је класификациони модел највеће тачности изабрао да податак припада сектору два.



Слика 3.6.1. Шема система са више класификатора и секторизацијом простора

4. ДОБИЈЕНИ РЕЗУЛТАТИ И ЊИХОВА АНАЛИЗА

Експериментално добијени резултати и њихова анализа приказани су у овом поглављу. Сваки од система позиционирања из претходног поглавља је засебно обрађен. Статистички параметри тачности на које се анализа фокусира су: средња грешка и медијана целог система као водећи приказ тачности, 67. перцентил и 95. перцентил као приказ стабилности модела, минимална и максимална грешка, стандардна девијација. За системе са секторизацијом простора посматраће се и тачност класификације као и појединачна средња грешка позиционирања сваког SVR модела појединачних сектора. Метрика која је коришћена приликом израчунавања ових параметара је еуклидска дистанца.

4.1. Анализа основног SVR модела

Основни модел, који подразумева коришћење само SVR алгоритма без поделе простора, даје најлошије перформансе. Коришћење једног SVR модела у конкретном примеру где тачност позиционирања није од пресудног значаја може бити прихватљиво. Некада није од пресудног значаја прецизно одредити позицију корисника са тачношћу реда величине неколико центиметара, као код одређених сложенијих система – пример аутономно управљање возилима, већ је довољно знати у којој просторији се корисник налази – прихватљива грешка до неколико метара. Свакако, применом техника из претходних поглавља тачност се може побољшати, на чему ће бити фокус у наредним деловима поглавља.

4.1.1. Анализа параметара

У Табели 4.1.1.1. испод могу се видети перформансе овог система. Средња грешка је скоро 9m, а медијана 7m. Перцентил 67 је скоро 10m, што модел шини релативно стабилним, али ипак са великим грешкама. У наредним системима треба што могуће више смањити ове вредности. Хиперпараметри јединог SVR модела, оптимизовани *GridSearchCV* методом, су следећи: $C=1$; $\text{kernel}='rbf'$; $\text{gamma}='scale'$; $\text{epsilon}=0.01$.

Табела 4.1.1. Приказ статистичких параметара основног система

Средња грешка [m]	Медијана грешке [m]	p67 [m]	p95 [m]	Стандардна девијација[m]	Најмања грешка [m]	Највећа грешка [m]
8.82	7.00	9.86	19.43	6.48	1.49	38.56

4.2. Анализа система са једним SVC класификатором и секторизацијом простора

Анализа система са једним SVC класификатором и секторизацијом простора, биће извршена за два, четири, шест, осам, десет и дванаест сектора. За сваки ће бити приказани статистички параметри целокупног система. Додатно, за систем са највећом тачношћу позиционирања биће приказане и вредности оптимизованих хиперпараметара појединачних SVR модела за сваки сектор. У току анализе праћене су и средње грешке позиционирања за сваки сектор, као и хиперпараметри сваког SVR модела. Због прегледности, наведени су само хиперпараметри SVR модела за опцију поделе простора која даје највећу тачност. Методом *GridSearchCV* оптимизовани су хиперпараметри SVC модела. У Табели 4.2.1. у наставку налазе се могуће вредности ових параметара. Методи *GridSearchCV* прослеђене су вредности

и за оптимизацију хиперпараметара сваког SVR модела појединачно, које се налазе у Табели 4.2.2. испод. Исте опције за SVC и SVR моделе се користе за систем са више класификатора. Приликом оптимизације, коришћена је *k-fold* крос-валидација са $k=5$ односно $k=2$ подскупа тренинг података за које су се у конкретном примеру добиле најбоље перформансе. Поента *k-fold* крос-валидације је подела тренинг скупа података на k непреклапајућих подскупа. Тренирање модела се врши са $k-1$ подскупа, док се модел валидира над преосталим подгрупом који се назива валидациони подскуп. Овакав процес тренирања се понавља k пута, сваки од k подскупа мора једном бити валидациони подскуп [9]. На овај начин модел ће имати ширу слику и боље генерализовати проблем, а *GridSearchCV* метода ће одредити вредности хиперпараметара који у просеку дају најбоље могуће резултате.

Табела 4.2.1. Приказ могућих опција хиперпараметара SVC модела за GridSearchCv методу

<i>GridSearchCV</i>	C	kernel	gamma
Могуће вредности хиперпараметара SVR модела	0.1	'rbf'	'scale'
	0.5		'auto'
	1		
	2		
	5		
	10		
	100		

Табела 4.2.2. Приказ могућих опција хиперпараметара SVR модела за GridSearchCv методу

<i>GridSearchCV</i>	C	Kernel	gamma	epsilon
Могуће вредности хиперпараметара SVR модела	0.1	'rbf'	'scale'	0.01
	1		'auto'	0.1
	10			0.2
	50			0.3
	75			0.4
	100			0.5
	200			0.6
	500			0.7
				0.8
				0.9
				1

4.2.1. Подела на два сектора – један SVC

Може се приметити да је тачност класификатора за два сектора веома висока, чак 98.77%, што обезбеђује да се податак добро класификује у одговарајући сектор. Очекује се да са порастом броја сектора ова тачност опадне, али ће у том случају SVR боље одређивати позиције података, па ће укупна тачност система постати боља. Такође, очекује се и чешће прављење грешака малих растојања и знатно смањена појава грешака великих растојања.

Како се цео простор дели само на два сектора, они су релативно велики, па SVR модели имају простора да праве веће грешке. У последњој колони табеле налазе се средње грешке предикција модела за сектор у ком се налазе.

4.2.2. Подела на четири сектора – један SVC

Примећује се да је тачност класификатора опала за 5.5% од претходног модела. Укупна тачност позиционирања је боља, средња грешка је мања за 0.37m, а медијана за 0.09 m. Ипак, пун потенцијал секторизације простора очекује за поделу на више сектора.

Уочава се да је максимална средња грешка предикције мања од претходног система, јер су сектори мањи па се предикција врши за мању област, а сложеност проблема смањује. Очекује се да се повећањем броја сектора ове грешке још више смање.

4.2.3. Подела на шест сектора – један SVC

Статистички параметри у Табели 4.2.3. показују значајнија побољшања у тачности рада система. Иако је тачност класификатора на 87.04%, укупна средња грешка је испод 8m, тачније 7.89m. Медијана грешака предикција је мања за 0.81m и износи 5.74m.

При подели простора на шест сектора SVR модели показују значајно боље перформансе у односу на претходне поделе. Закључује се да су елементи у секторима сличнији него у претходним примерима. Сложеност проблема је значајно смањена и SVR модели лакше уче. Наведено се доказује разноврсним вредностима хиперпараметара за различите SVR моделе.

4.2.4. Подела на осам сектора – један SVC

Подела на осам сектора за конкретан простор показује нешто лошије резултате од очекиваног, што се може видети у Табели 4.2.3. Иако је тачност класификатора 88.27%, што је веће од случаја са шест сектора, средња грешка и медијана су за око 0.7m односно око 0.6m веће. Систем са поделом простора на осам сектора је најнеповољнији за коришћење и такође прави највеће грешке.

Због неповољне секторизације SVR модели теже уче и дају лошије резултате. Велики празни простори који представљају дворишта зграде ЕТФ-а и тиме не спадају у *indoor простор* налазе се по средини одређених сектора. Како у овим деловима сектора нису вршена мерења, моделима је значајно отежано учење и генерализација проблема.

4.2.5. Подела на десет сектора – један SVC

Коришћење десет сектора даје боље резултате него када се користе два и осам сектора или када се секторизација уопште не користи. Ипак, боља тачност се добија за коришћење шест или чак четири сектора, те овај вид секторизације није оптималан. У Табели 4.2.3. налазе се статистички параметри овакве секторизације. Занимљиво је уочити значајан пад тачности SVC класификатора у односу на поделу на осам сектора, што доводи до горе средње грешке позиционирања.

Већина SVR модела постиже веома добре резултате, али неколико њих, због самог изгледа простора и великих празнина у сред сектора – поменутих дворишта зграде ЕТФ-а, показује нешто лошије резултате. Два модела показују лошије резултате која имају средњу грешку већу од 10m. Комбинација SVR модела и знатно мање тачности класификације доприноси мањој свеукупној средњој грешки позиционирања.

4.2.6. Подела на дванаест сектора – један SVC

Подела на дванаест сектора показује најбоље резултате. За сада је подела простора на шест сектора давала најбољу тачност па ћемо ово решење упоредити са тим. У Табели 4.2.3. испод приказани су статистички параметри код овакве поделе, а у наставку ће се укратко проћи кроз поређење ове две секторизације. Овакав вид поделе даје за 0.45m мању средњу грешку позиционирања него подела на шест сектора – 7.44m у односу на 7.89m, али мало већу медијану – 5.80m у односу на 5.74m. Перцентил п67 је мањи за 0.54m, а п95 за 1.16m, што указује на већу робусност и стабилност оваког система.

Упркос знатно мањој тачности класификације него код шест сектора, овакав вид секторизације веома одговара SVR моделима који показују веома добре резултате. Како су подаци у секторима повољно позиционирани, регресионим моделима се пружа добар увид у генералне карактеристике проблема. У наставку се налази и Табела 4.2.6.1 са хиперпараметрима и средњим грешкама ових регресионих модела.

Табела 4.2.3. Приказ статистичких параметара за појединачне SVR моделе за дванаест сектора и једним SVC

NUM_SECT=12	C	Кернел функција	gamma	epsilon	Средња грешка по сектору [m]
(SVR) ₁	0.1	'rbf'	'scale'	0.01	5.28
(SVR) ₂	1	'rbf'	'scale'	0.01	6.47
(SVR) ₃	1	'rbf'	'scale'	0.01	5.46
(SVR) ₄	0.1	'rbf'	'scale'	0.01	5.77
(SVR) ₅	1	'rbf'	'scale'	0.01	12.30
(SVR) ₆	0.1	'rbf'	'scale'	0.01	9.91
(SVR) ₇	0.1	'rbf'	'scale'	0.01	6.65
(SVR) ₈	0.1	'rbf'	'auto'	0.01	7.58
(SVR) ₉	1	'rbf'	'scale'	0.01	8.80
(SVR) ₁₀	1	'rbf'	'auto'	0.01	9.26
(SVR) ₁₁	0.1	'rbf'	'scale'	0.01	9.53
(SVR) ₁₂	500	'rbf'	'auto'	0.01	5.86

Табела 4.2.4. Приказ статистичких параметара система са једним SVC класификатором у зависности од броја сектора

Број сектора	2	4	6	8	10	12
Тачност класификатора [%]	98.77	93.21	87.04	88.27	81.48	79.01
Средња грешка [m]	8.59	8.22	7.89	8.62	8.32	7.44
Медијана грешке [m]	6.64	6.55	5.74	6.37	5.92	5.80
Перцентил 67 [m]	9.64	8.47	8.46	8.68	8.05	7.92
Перцентил 95 [m]	20.11	18.84	20.50	19.85	24.77	19.34
Стандардна девијација [m]	7.00	6.69	6.70	9.34	7.65	6.58
Најмања грешка [m]	0.31	0.56	0.36	0.38	0.41	0.02
Највећа грешка [m]	54.22	40.34	41.42	77.35	41.64	41.40

4.3. Анализа система са више класификатора и секторизацијом простора

Анализа система извршена је аналогно анализи претходног. Побољшање које је уведено у односу на претходне системе јесте више различитих модела за класификацију који имају могућност гласања односно већинског одлучивања. У неким случајевима већинско одлучивање не показује боље резултате од појединачних класификатора. Како би се добиле најбоље перформансе система, бира се класификатор са највећом тачношћу. Поред основног SVC класификатора, уводе се kNN и MLP класификациони модели. У Табели 4.3.1. у наставку налазе се могуће вредности хиперпараметара ових модела чију оптималну комбинацију проналази *GridSearchCV* метода. Током анализе, праћене су вредности тачности сваког појединачног класификатора, као и већинског одлучивања.

Табела 4.3.1. Приказ могућих опција хиперпараметара kNN и MLP модела за *GridSearchCv* методу

<i>GridSearchCV</i>	Класификациони модел							
	kNN				MLP			
	n_neighbors	weights	metric	p	hidden_layer_sizes	alpha	activation	learning_rate_init
Могуће вредности хиперпараметара класификационих модела	1	'uniform'	Euclidean	1	8	0.0001	'relu'	0.001
	3	'distance'	Manhattan	2	16	0.001	'tanh'	0.01
			Minkowski		16, 8	0.01		
					32, 16			

4.3.1. Подела на два сектора – више класификатора

У Табели 4.3.2. наведени су статистички параметри овог система. Прва разлика која се уочава у поређењу са претходним је нешто већа тачност класификације за поделу на два сектора и примена kNN класификатора уместо SVC. Ипак, коришћени SVR модели показују сличне или мало лошије карактеристике те су статистички параметри исти као у претходном систему.

4.3.2. Подела на четири сектора – више класификатора

На основу Табеле 4.3.3 класификатор највеће тачности је SVC. С тога се не може очекивати побољшање јер би већинско одлучивање или коришћење других модела класификације погоршало укупну тачност позиционирања. Статистички параметри су исти као код претходног система.

4.3.3. Подела на шест сектора – више класификатора

Као и код поделе на четири сектора, и овде највећу тачност пружа SVC модел. Нема побољшања и сви параметри и перформансе система остају непромењени. Други типови класификатора заједно са већинским одлучивањем показују лошију тачност за око 1.24%-1.85%.

4.3.4. Подела на осам сектора – више класификатора

Први пут се користи механизам већинског одлучивања. Тиме се повећава тачност класификације за 3%, а смањују средња грешка из медијана грешке позиционирања за 0.72m односно 0.38m, респективно. У Табели 4.3.2. се уочава значајно побољшање у раду система са поделом простора на осам сектора, модел постаје стабилнији, а највећа грешка је много мања. Већинско одлучивање је омогућило велико побољшање у раду оваквог система.

4.3.5. Подела на десет сектора – више класификатора

Већинско одлучивање и овде показује најбоље резултате. Побољшање тачности класификације је много мање него код поделе на осам сектора, свега 1.24%, али су ипак средња грешка и медијана мање за 0.30m односно 0.11m, респективно. Већинско одлучивање и овде уводи побољшање рада система.

4.3.6. Подела на дванаест сектора – више класификатора

Ипак, система са највећом тачношћу позиционирања остаје подела простора на дванаест сектора са коришћењем SVC модела класификације. Већинско одлучивање се показало лошије за 0.61% од најтачнијег модела те би остварило лошије карактеристике.

Табела 4.3.2. Приказ статистичких параметара система са више класификатора у зависности од броја сектора

Број сектора	2	4	6	8	10	12
Најбољи ккласификатор	kNN	SVC	SVC	Већинско одлучивање	Већинско одлучивање	SVC
Тачност класификатора[%]	99.38	93.21	87.04	91.36	82.72	79.01
Средња грешка[m]	8.59	8.22	7.89	7.90	8.02	7.44
Медијана грешке[m]	6.64	6.56	5.74	5.99	5.81	5.80
Перцентил 67[m]	9.64	8.47	8.46	8.01	7.88	7.92
Перцентил 95[m]	20.11	18.84	20.50	17.35	23.91	19.34
Стандардна девијација[m]	7.01	6.69	6.70	7.51	7.25	6.58
Најмања грешка[m]	0.31	0.56	0.36	0.38	0.41	0.02
Највећа грешка[m]	54.22	40.34	41.42	47.48	41.64	41.40

Табела 4.3.3. Приказ тачности различитих класификатора у зависности од броја сектора

Број сектора		2	4	6	8	10	12
Тачност класификатора [%]	SVC	98.77	93.21	87.04	88.27	81.48	78.40
	kNN	99.38	93.21	85.80	86.42	82.10	77.78
	MLP	98.77	90.12	85.19	90.74	82.10	70.37
	Већинско одлучивање	98.77	92.59	85.80	91.36	82.72	79.01

5. ЗАКЉУЧАК

Интеграцијом техника машинског учења у широко распрострањене WLAN мреже могуће је развити систем за *indoor* позиционирање корисника који поседује задовољавајуће перформансе. Ред тачности предложеног система није довољан да се опслуже сервиси који захтевају тачност реда величине центиметра, али се могу користити за одређивање просторије, а некад и дела просторије у ком се корисник налази. Применом техника геометријске секторизације простора и избора најтачнијег класификатора, најбоље остварене карактеристике система су 7.44m за средњу грешку, а 5.80m за медијану грешке позиционирања. Минимална остварена грешка је 0.02m што је корисника позиционирало са веома великом тачношћу.

SVM техника машинског учења је пружила веома добре перформансе за конкретан проблем. У комбинацији са kNN алгоритмом и вештачким неуралним мрежама се те перформансе у одређеним случајевима могу побољшати. Потенцијална побољшања овог система се могу потражити у коришћењу неких другачијих модела вештачке интелигенције, нпр. *XgBoost* [4] или *RandomForest* [3] класификатора уместо коришћених kNN и MLP. Треба водити рачуна и о контроли претрениравања поменутих модела који своје најбоље перформансе постижу за много веће скупове података од коришћене базе. Додатни простор за потенцијално побољшање тачности система је увођење различитих типова регресионих модела у сваки сектор. Тиме би се потенцијално побољшала генерализација проблема и постигли још бољи резултати у самим секторима. Треба дати простора и *GridSearchCV* методи са већим спектром могућих вредности, како би се потенцијално пронашла погоднија комбинација хиперпараметара модела за конкретан проблем.

На основу изведених резултата, предложени систем позиционирања корисника у *indoor* окружењу показује веома добре карактеристике, пружа брзо позиционирање, а одликују га и приступачност архитектуре и једноставна имплементација. Увођењем већинског одлучивања класификатора за одређене поделе се постижу значајно бољи резултати, а коришћењем модела веће тачности се потенцијално може остварити пун потенцијал оваквог унапређења система.

6.ЛИТЕРАТУРА

- [1] N. Singh, S. Choe, R. Punmiya, *Machine Learning Based Indoor Localization Using WLAN RSSI Fingerprints: An Overview*, 2025
- [2] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] scikit-learn Machine Learning in Python, Available: <https://scikit-learn.org/stable/> (08.10.2025.)
- [4] XGBoost Documentation, Available: <https://xgboost.readthedocs.io/en/stable/index.html> (08.10.2025.)
- [5] NumPy The fundamental package for scientific computing with Python, Available: <https://numpy.org/> (08.10.2025.)
- [6] Matplotlib: Visualization with Python, Available: <https://matplotlib.org/> (08.10.2025.)
- [7] pandas - Python Data Analysis Library, Available: <https://pandas.pydata.org/> (16.10.2025.)
- [8] JETBRAINS PyCharm, Available: <https://www.jetbrains.com/pycharm/> (08.10.2025.)

Списак скраћеница

AI	<i>Artificial Intelligence</i>
ЕТФ	<i>Електротехнички факултет Универзитета у Београду</i>
GPS	<i>Global Positioning System</i>
kNN	<i>k-Nearest Neighbor</i>
ML	<i>Machine Learning</i>
MLP	<i>Multilayer Perceptron</i>
RSSI	<i>Received Signal Strength Indicator</i>
SVM	<i>Support Vector Machine</i>
SVR	<i>Support Vector Regression</i>
WLAN	<i>Wireless Local Area Network</i>

Списак слика

Слика 3.1.1. Положај <i>access point</i> -а и вршених мерења у згради ЕТФ-а.....	4
Слика 3.3.1. Шема основног система.....	5
Слика 3.4.1. Приказ поделе података на укупно дванаест сектора.....	6
Слика 3.5.1. Шема система са једним SVC и секторизацијом простора	6
Слика 3.6.1. Шема система са више класификатора и секторизацијом простора	8

Списак табела

Табела 4.1.1. Приказ статистичких параметара основног система	9
Табела 4.2.1. Приказ могућих опција хиперпараметара SVC модела за GridSearchCv методу	10
Табела 4.2.2. Приказ могућих опција хиперпараметара SVR модела за GridSearchCv методу	10
Табела 4.2.3. Приказ статистичких параметара за појединачне SVR моделе за дванаест сектора и једним SVC	12
Табела 4.2.4. Приказ статистичких параметара система са једним SVC класификатором у зависности од броја сектора.....	13
Табела 4.3.1. Приказ могућих опција хиперпараметара kNN и MLP модела за GridSearchCv методу.....	13
Табела 4.3.2. Приказ статистичких параметара система са више класификатора у зависности од броја сектора.....	15
Табела 4.3.3. Приказ тачности различитих класификатора у зависности од броја сектора	15